




# 大创参考文献学习笔记

作者：Lollins

时间：September 20, 2023



改变人生的事情，你必须冒险；意义非凡的事情，大多碰巧发生；不重要的事，才有周全的计划。



# 前言

2023/8/14, 开始阅读老师给的三篇英文文献, 用此文补充一些看大创文献中遇到的知识点。

2023/9/19, 过去一个月了, 最近在网上看到了 `ElegantTeX` 的模板, 感觉好好看, 花了一天的时间把相关的格式和细节都改了。好看了好多, 不过字体变小了不少。

Lollins

September 20, 2023

# 目录

第 1 章	Matrix Theorem	iii
1.1	Laplace Matrix	iii
1.2	Kronecker Product	vii
1.3	Frobenius Norm and Inner Product	viii
1.4	Diagonally-dominant Matrix	viii
1.5	Hurwitz Matrix	viii
第 2 章	Convex Optimization	x
2.1	Convex Function	x
第 3 章	ODE	xv
3.1	Lyapunov Stability Analysis	xv
3.2	Exponentially Stable	xvi
3.3	Gronwall-Bellman Inequality	xvii
第 4 章	Calculus	xviii
4.1	矩阵与范数求导	xviii
4.1.1	梯度	xviii
4.1.2	矩阵微分	xviii
4.2	向量函数的 <i>Taylor</i> 公式	xviii
第 5 章	Game Theorem	xix
第 6 章	Advanced Algebra	xx
6.1	Gerschgorin Circle Theorem—特征值估计	xx
6.2	Jordan Form	xx
6.3	矩阵特征值不等式	xxi
附录 A	[1]Distributed Nash Equilibrium Seeking by a Consensus Based Approach	xxii
A.1	Terminology	xxii
A.2	式 (8) 中的 Hurwitz Matrix	xxii
A.3	线性化式 (19)	xxii
A.4	式 (20) 中 $\bar{k}B$ is Hurwitz	xxii

# 第 1 章 Matrix Theorem

## 1.1 Laplace Matrix

### Laplace Operator

对于多元函数  $f(x_1, \dots, x_n)$  的 Laplace Operator 为

$$\Delta f = \sum_{i=1}^n \frac{\partial^2 f}{\partial x_i^2} \quad (1.1)$$

**例题 1.1** 三元函数  $f(x, y, z)$  的 Laplace Operator 为

$$\Delta f = \frac{\partial^2 f}{\partial x^2} + \frac{\partial^2 f}{\partial y^2} + \frac{\partial^2 f}{\partial z^2}$$

### 数值微分

根据导数近似计算公式，当  $\Delta$  近似等于 0 时，我们可以得到  $f$  的导数为

$$\begin{aligned} f'(x) &\approx \frac{f(x + \Delta x) - f(x)}{\Delta x} \\ f''(x) &\approx \frac{f'(x + \Delta x) - f'(x)}{\Delta x} \\ &\approx \frac{f(x + \Delta x) + f(x - \Delta x) - 2f(x)}{(\Delta x)^2} \end{aligned}$$

对二元函数  $f(x, y)$ ，我们对其使用 Laplace Operator，得到

$$\begin{aligned} \Delta f &= \frac{\partial^2 f}{\partial x^2} + \frac{\partial^2 f}{\partial y^2} \\ &\approx \frac{f(x + \Delta x, y) + f(x - \Delta x, y) - 2f(x, y)}{(\Delta x)^2} \\ &\quad + \frac{f(x, y + \Delta y) + f(x, y - \Delta y) - 2f(x, y)}{(\Delta y)^2} \end{aligned}$$

把此二元函数离散化，为了简化，假设  $x$  和  $y$  的增量即步长为 1，即

$$\Delta x = x_{i+1} - x_i = 1, \Delta y = y_{j+1} - y_j = 1$$

点  $(x_i, y_j)$  处的 Laplace Operator 可以用下面的公式近似代替

$$\begin{aligned} &\frac{f(x_i + \Delta x, y_j) + f(x_i - \Delta x, y_j) - 2f(x_i, y_j)}{(\Delta x)^2} \\ &+ \frac{f(x_i, y_j + \Delta y) + f(x_i, y_j - \Delta y) - 2f(x_i, y_j)}{(\Delta y)^2} \\ &= \frac{f(x_{i+1}, y_j) + f(x_{i-1}, y_j) - 2f(x_i, y_j)}{1^2} + \frac{f(x_i, y_{j+1}) + f(x_i, y_{j-1}) - 2f(x_i, y_j)}{1^2} \\ &= f(x_{i+1}, y_j) + f(x_{i-1}, y_j) + f(x_i, y_{j+1}) + f(x_i, y_{j-1}) - 4f(x_i, y_j) \end{aligned}$$

这是非常优美的结果，它就是  $(x_i, y_j)$  的 4 个相邻点处的函数值之和与 4 倍的  $(x_i, y_j)$  点处的差值，如图 1.1 所示

示




图 1.1

基于这种表示，Laplace Operator 的计算公式可以表示为

$$\begin{aligned}
 \Delta f &= f(x_{i+1}, y_j) + f(x_{i-1}, y_j) + f(x_i, y_{j+1}) + f(x_i, y_{j-1}) - 4f(x_i, y_j) \\
 &= f(x_{i+1}, y_j) - f(x_i, y_j) + f(x_{i-1}, y_j) - f(x_i, y_j) \\
 &\quad + f(x_i, y_{j+1}) - f(x_i, y_j) + f(x_i, y_{j-1}) - f(x_i, y_j) \\
 &= \sum_{(k,l) \in N(i,j)} (f(x_k, y_l) - f(x_i, y_j))
 \end{aligned} \tag{1.2}$$

其中  $N(i, j)$  为  $(x_i, y_j)$  的邻居节点

### 图的邻接矩阵与加权度矩阵

图是一种几何结构，对它的研究起源于古老的哥尼斯堡七桥问题。一个图  $G(\text{graph})$  由顶点和边构成，通常将顶点的集合记为  $V(\text{vertex})$ ，边的集合记为  $E(\text{edge})$ 。边由其连接的起点和终点表示。如图1.2所示，它是一个典型的图。




图 1.2

图的边可以有方向的，也可以是无方向的，前者被称为有向图，后者被称为无向图。邻接矩阵是用来方便存储图的结构，用线性代数方法研究图的问题。

如果一个图有  $n$  个顶点，其邻接矩阵  $W$  为  $n \times n$  的矩阵，矩阵元素  $w_{ij}$  表示边  $(i, j)$  的权重，如果矩阵两

个顶点之间没有边连接，则记为 0。对于无向连接矩阵，满足  $w_{ij} = w_{ji}$ 。图1.2的邻接矩阵如下

$$\begin{bmatrix} 0 & 2 & 0 & 0 & 0 & 5 & 0 \\ 2 & 0 & 4 & 3 & 0 & 0 & 0 \\ 0 & 4 & 0 & 4 & 0 & 0 & 0 \\ 0 & 3 & 4 & 0 & 4 & 0 & 2 \\ 0 & 0 & 0 & 4 & 0 & 0 & 0 \\ 5 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 2 & 0 & 0 & 0 \end{bmatrix}$$

对于无向图，顶点的加权重是与该顶点相关的所有边的权重之和。对于无向图连接矩阵  $W$ ，顶点  $i$  的加权重为  $W$  第  $i$  行元素之和

$$d_i = \sum_{j=1}^n w_{ij}$$

加权重矩阵  $D$  为对角矩阵，其主对角线元素为每个顶点的加权重，其他位置的元素为 0。

$$d_{ii} = d_i = \sum_{j=1}^n w_{ij} \quad (1.3)$$

对于图1.2，它的加权重矩阵如式1.4所示

$$\begin{bmatrix} 7 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 9 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 8 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 13 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 4 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 5 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 2 \end{bmatrix} \quad (1.4)$$

## Laplace Matrix

如果将图的顶点处的值看作是函数值，则在顶点  $i$  处的 Laplace Operator 为

$$\Delta f_i = \sum_{j \in N_i} (f_i - f_j)$$

这里的  $N_i$  为顶点  $i$  的所有邻居顶点集合。这里我们调换了  $f_i$  和  $f_j$  的位置，和之前的 Laplace Operator 相比，相当于多了一个负号。由于图的边可以带有权重，我们可以在上面的计算公式中加上权重

$$\Delta f_i = \sum_{j \in N_i} w_{ij} (f_i - f_j) \quad (1.5)$$

这一推广如图1.3所示，图中图中红色的顶点是  $i$ ，蓝色的顶点是它的邻居顶点，灰色的顶点是其他顶点。

如果  $j$  不是  $i$  的邻居，则  $w_{ij} = 0$ 。因此式1.5也可以写做

$$\Delta f_i = \sum_{j \in N_i} w_{ij} (f_i - f_j) = \sum_{j \in N_i} w_{ij} f_i - \sum_{j \in N_i} w_{ij} f_j = d_i f_i - \mathbf{w}_i \mathbf{f} \quad (1.6)$$

这里的  $d_i$  就是第  $i$  个节点的加权重， $\mathbf{w}_i$  为邻接矩阵第  $i$  行， $\mathbf{f}$  是所有顶点的值构成的列向量， $\mathbf{w}_i \mathbf{f}$  是二者的内积。




图 1.3

对图的所有顶点，我们有

$$\begin{aligned} \Delta f &= \begin{bmatrix} \Delta f_1 \\ \dots \\ \Delta f_n \end{bmatrix} = \begin{bmatrix} d_1 f_1 - \mathbf{w}_1 \mathbf{f} \\ \dots \\ d_n f_n - \mathbf{w}_n \mathbf{f} \end{bmatrix} = \begin{bmatrix} d_1 & \dots & \dots \\ \dots & \dots & \dots \\ \dots & \dots & d_n \end{bmatrix} \begin{bmatrix} f_1 \\ \dots \\ f_n \end{bmatrix} - \begin{bmatrix} \mathbf{w}_1 \\ \dots \\ \mathbf{w}_n \end{bmatrix} \begin{bmatrix} f_1 \\ \dots \\ f_n \end{bmatrix} \\ &= (\mathbf{D} - \mathbf{W}) \mathbf{f} \end{aligned} \quad (1.7)$$

我们在邻接矩阵和加权重度矩阵的基础上定义 **Laplace Matrix**。假设无向图  $G$  有  $n$  个顶点，邻接矩阵为  $W$ ，加权重度矩阵为  $D$ 。**Laplace Matrix** 定义为加权重度矩阵与邻接矩阵之差，即

$$L = D - W \quad (1.8)$$

则图1.2的 Laplace Matrix 为

$$\begin{bmatrix} 7 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 9 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 8 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 13 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 4 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 5 & 0 \\ 0 & 0 & 0 & 0 & 0 & 5 & 0 \end{bmatrix} - \begin{bmatrix} 0 & 2 & 0 & 0 & 0 & 5 & 0 \\ 2 & 0 & 4 & 3 & 0 & 0 & 0 \\ 0 & 4 & 0 & 4 & 0 & 0 & 0 \\ 0 & 3 & 4 & 0 & 4 & 0 & 2 \\ 0 & 0 & 0 & 4 & 0 & 0 & 0 \\ 5 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 2 & 0 & 0 & 0 \end{bmatrix} = \begin{bmatrix} 7 & -2 & 0 & 0 & 0 & -5 & 0 \\ -2 & 9 & -4 & -3 & 0 & 0 & 0 \\ 0 & -4 & 8 & -4 & 0 & 0 & 0 \\ 0 & -3 & -4 & 13 & -4 & 0 & -2 \\ 0 & 0 & 0 & -4 & 4 & 0 & 0 \\ -5 & 0 & 0 & 0 & 0 & 5 & 0 \\ 0 & 0 & 0 & -2 & 0 & 0 & 2 \end{bmatrix}$$

显然 Laplace Matrix 的每行元素之和都为 0。

## Properties

1. 对任意向量  $\mathbf{f} \in \mathbb{R}^n$ ，有

$$\mathbf{f}^T \mathbf{L} \mathbf{f} = \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n w_{ij} (f_i - f_j)^2$$

2. Laplace Matrix 是对称半正定矩阵；

3. Laplace Matrix 的最小特征值为 0，其对应的特征向量为常向量 1，即所有分量为 1，即  $L \mathbf{1}_n = \mathbf{0} \mathbf{1}_n = \mathbf{0}_n$ ；

4. Laplace Matrix 有  $n$  个非负实数特征值，并且满足

$$\lambda_n \geq \dots \geq \lambda_1 \geq 0$$

相关证明可以参考这篇知乎文章 [理解图的拉普拉斯矩阵](#)

## 1.2 Kronecker Product

### 定义 1.1

给定任意矩阵  $X \in \mathbb{R}^{m \times n}$  和  $Y \in \mathbb{R}^{p \times q}$  则矩阵  $X$  和  $Y$  的 Kronecker Product 为

$$X \otimes Y = \begin{bmatrix} x_{11}Y & x_{12}Y & \cdots & x_{1n}Y \\ x_{21}Y & x_{22}Y & \cdots & x_{2n}Y \\ \vdots & \vdots & \ddots & \vdots \\ x_{m1}Y & x_{m2}Y & \cdots & x_{mn}Y \end{bmatrix} \in \mathbb{R}^{(mp) \times (nq)} \quad (1.9)$$

其中， $\otimes$  表示 Kronecker Product。



注：根据式1.9，我们可以得到

$$Y \otimes X = \begin{bmatrix} y_{11}X & y_{12}X & \cdots & y_{1q}X \\ y_{21}X & y_{22}X & \cdots & y_{2q}X \\ \vdots & \vdots & \ddots & \vdots \\ y_{p1}X & y_{p2}X & \cdots & y_{pq}X \end{bmatrix} \in \mathbb{R}^{(mp) \times (nq)}$$

这意味着  $X \otimes Y$  和  $Y \otimes X$  不相同，即 Kronecker Product 不存在交换律。

### Properties

#### 1. 结合律 (associativity)

$$X \otimes Y \otimes Z = (X \otimes Y) \otimes Z = X \otimes (Y \otimes Z) \quad (1.10)$$

#### 2. 分配律 (distributivity)

$$(X + Y) \otimes Z = X \otimes Z + Y \otimes Z \quad (1.11)$$

#### 3. 给定任意矩阵 $X \in \mathbb{R}^{m \times n}$ 和 $Y \in \mathbb{R}^{p \times q}$ ，则

$$(X \otimes Y)^T = X^T \otimes Y^T \quad (1.12)$$

#### 4. 给定任意矩阵 $X \in \mathbb{R}^{m \times n}$ 、 $Y \in \mathbb{R}^{s \times t}$ 、 $U \in \mathbb{R}^{n \times p}$ 和 $V \in \mathbb{R}^{t \times q}$ ，则

$$(X \otimes Y)(U \otimes V) = (XU) \otimes (YV) \in \mathbb{R}^{(ms) \times (pq)} \quad (1.13)$$

#### 5. 给定矩阵 $X \in \mathbb{R}^{m \times n}$ 和 $Y \in \mathbb{R}^{p \times q}$ 都是非奇异的，则

$$(X \otimes Y)^{-1} = X^{-1} \otimes Y^{-1} \quad (1.14)$$

还有一些特殊性质（懒打公式了，先从网上找了图片截屏放进去），如图1.4所示

【性质6】迹：  $\text{tr}(X \otimes Y) = \text{tr}(X) \cdot \text{tr}(Y)$ ,  $X \in \mathbb{R}^{m \times m}$ ,  $Y \in \mathbb{R}^{n \times n}$

【性质7】F-范数：  $\|X \otimes Y\|_F = \|X\|_F \cdot \|Y\|_F$

【性质8】 $\ell_2$  范数：  $\|x \otimes y\|_2 = \|x\|_2 \cdot \|y\|_2$

【性质9】行列式：  $\det(X \otimes Y) = \det(X)^n \cdot \det(Y)^m$ ,  $X \in \mathbb{R}^{m \times m}$ ,  $Y \in \mathbb{R}^{n \times n}$

【性质10】秩：  $\text{rank}(X \otimes Y) = \text{rank}(X) \cdot \text{rank}(Y)$

图 1.4

本节主要参考了知乎的 [代数基础 | Kronecker 积](#)，文章中给出了详细的证明。



## 1.3 Frobenius Norm and Inner Product

### 定义 1.2

对于矩阵  $A \in C^{m \times n}$ ，其 Frobenius Norm 为

$$\|A\|_F = \left( \sum_{i=1}^m \sum_{j=1}^n |a_{ij}|^2 \right)^{\frac{1}{2}} \quad (1.15)$$

其 Frobenius Inner Product 为

$$\langle A, B \rangle_F = \sum_{j=1}^m \sum_{i=1}^n A_{ij}^* B_{ij} \quad (1.16)$$



又由于

$$\begin{aligned} \text{tr}(A^H B) &= \sum_{i=1}^n (A^H B)_{ii} \\ &= \sum_{i=1}^n \sum_{k=1}^m A_{ik}^H B_{ki} \\ &= \sum_{i=1}^n \sum_{k=1}^m A_{ki}^* B_{ki} \end{aligned}$$

故我们可以得到

$$\langle A, B \rangle_F = \text{tr}(A^H B)$$

本节主要参考了 [Frobenius 范数和内积的关系](#)

## 1.4 Diagonally-dominant Matrix

### 定义 1.3 (Strictly Diagonally-dominant Matrix)

对于一个矩阵  $A_{n \times n}$ ，满足  $\forall i = 1, 2, \dots, n$ ，有

$$|a_{ii}| > \sum_{j \neq i} |a_{ij}| \quad (1.17)$$

那么我们称  $A_{n \times n}$  为 Strictly Diagonally-dominant Matrix。



### 定理 1.1

如果矩阵  $A$  严格对角占优，则  $A$  非奇异。



具体的证明可以参考这篇文章[严格对角占优矩阵非奇异](#)。

## 1.5 Hurwitz Matrix

### 定义 1.4 (Hurwitz Matrix)

给定一个多项式（多项式的所有根都有负实部）

$$p(z) = a_n z^n + a_{n-1} z^{n-1} + \dots + a_1 z + a_0 \quad (1.18)$$

和  $n$  阶矩阵

$$H = \begin{pmatrix} a_{n-1} & a_{n-3} & a_{n-5} & \cdots & \cdots & \cdots & 0 & 0 & 0 \\ a_n & a_{n-2} & a_{n-4} & & & & \vdots & \vdots & \vdots \\ 0 & a_{n-1} & a_{n-3} & & & & \vdots & \vdots & \vdots \\ \vdots & a_n & a_{n-2} & \ddots & & & 0 & \vdots & \vdots \\ \vdots & 0 & a_{n-1} & & \ddots & & a_0 & \vdots & \vdots \\ \vdots & \vdots & a_n & & & \ddots & a_1 & 0 & \vdots \\ \vdots & \vdots & 0 & & & & a_2 & a_0 & \vdots \\ \vdots & \vdots & \vdots & & & & a_3 & a_1 & 0 \\ 0 & 0 & 0 & \cdots & \cdots & \cdots & a_4 & a_2 & a_0 \end{pmatrix} \quad (1.19)$$

那么称矩阵  $H$  为多项式  $p$  的 Hurwitz Matrix。

$p$  多项式的所有根都有负实部  $\iff H$  的所有顺序主子式大于 0。



**例题 1.2** 在 Mathematica 中调用函数指令，可以得到  $p(x) = 5 + 4x + 3x^2$  和  $p(x) = 5 + 4x + 3x^2 + 2x^3 + x^4$  的 2 阶与 4 阶的 Hurwitz Matrix，分别如图 1.5 和图 1.6 所示（原本想  $\text{\LaTeX}$  嵌入 mma 代码，奈何网上资料太少加上自己能力有限，嵌入失败，就截图放里面了）

```

ResourceFunction[\"HurwitzMatrix\"][5 + 4 x + 3 x^2, x] // MatrixForm

```

Output:  $\begin{pmatrix} 4 & 0 \\ 3 & 5 \end{pmatrix}$

图 1.5

```

ResourceFunction[\"HurwitzMatrix\"][5 + 4 x + 3 x^2 + 2 x^3 + x^4, x] // MatrixForm

```

Output:  $\begin{pmatrix} 2 & 4 & 0 & 0 \\ 1 & 3 & 5 & 0 \\ 0 & 2 & 4 & 0 \\ 0 & 1 & 3 & 5 \end{pmatrix}$

图 1.6

### 定理 1.2

求解  $n$  阶方阵的全部顺序主子式  $D_i$ ， $D_i$  表示矩阵的第  $i$  阶主子式。

1. 如果所有主子式  $D_i$  均为正，则系统稳定；
2. 如果存在某个主子式  $D_i$  为零，但其后续主子式均为正，则系统稳定；
3. 如果任意一个主子式  $D_i$  为负，则系统不稳定。



## 第 2 章 Convex Optimization

### 2.1 Convex Function

#### 基本的定义与性质

##### 定义 2.1 (Convex Function)

对于函数  $f: \mathbb{R}^n \rightarrow \mathbb{R}$ , 若满足  $\text{dom}(f) \subset \mathbb{R}^n$  是凸集,  $\forall t \in [0, 1], \forall \mathbf{x}, \mathbf{y} \in \text{dom}(f)$ , 有

$$f(t\mathbf{x} + (1-t)\mathbf{y}) \leq tf(\mathbf{x}) + (1-t)f(\mathbf{y}) \quad (2.1)$$

则这个函数是一个凸函数。如果等号处处不成立, 则称它是一个严格凸函数 (Strictly)。

##### 定义 2.2 (Concave Functions)

若  $-f$  是一个凸函数, 那么  $f$  所定义的函数就是凹函数。如果等号处处不成立, 则称它是一个严格凹函数。

注 1: 凸函数与凹函数不是二元对立的关系, 比如  $y = ax + bx \in \mathbb{R}$ , 它是凸函数也是凹函数

注 2: 无论是凸函数, 还是凹函数, 一定要求定义域为凸集。而且没有凹集的说法

##### 定义 2.3 (First-order Characterization of Convex Functions)

如果  $f$  一阶可导,  $\text{dom}(f)$  是凸的, 并且  $\forall \mathbf{x}, \mathbf{y} \in \text{dom}(f)$ , 有

$$f(\mathbf{y}) \geq f(\mathbf{x}) + \nabla f(\mathbf{x})^T (\mathbf{y} - \mathbf{x}) \quad (2.2)$$

则称它是一个凸函数。

其实定义2.3可以看成 *Taylor* 公式的一阶展开。




图 2.1

对于这个一阶条件定义, 可以参照图2.1来理解。

它给了我们一个重要的启示: 如果我们假设  $\nabla f(\mathbf{x}) = 0$ , 那么无论  $\mathbf{y}$  是什么, 都有  $f(\mathbf{y}) \geq f(\mathbf{x})$ 。潜在的意


思是，对于驻点为 0 的  $x$  点，我们取到了最小值。因此正如机器学习界经常说的一句话：当一个问题被证明是一个凸优化问题，那么基本上就可以算解决了。

#### 定义 2.4 (Second-order Characterization of Convex Functions)


如果  $f$  是二阶可微的， $\text{dom}(f)$  是凸的，并且  $\forall x \in \text{dom}(f), \nabla^2 f(x) \succeq 0$ 。那么  $f$  就是一个凸函数。




二阶导数（即  $\nabla^2 f$ ）是用来衡量一阶导数的变化率。考虑  $\text{dom}(f) \subset \mathbb{R}$  的一维情况，对应  $\nabla^2 f \geq 0$  画出  $\nabla f$  图像的三种情况，如图 2.2 所示，对应的  $f$  图像如 2.3 所示，我们可以发现图 2.3 都为凸函数。



(a)  $\nabla f$  在  $x$  轴上方



(b)  $\nabla f$  穿过  $x$  轴



(c)  $\nabla f$  在  $x$  轴下方

图 2.2:  $\nabla f$  图像的三种情况

#### 推论 2.1

如果  $f$  是凸函数，那么  $\forall x, y$ ，我们有

$$(\nabla f(x) - \nabla f(y))^T (x - y) \geq 0 \quad (2.3)$$



**证明** 1、从一维的角度理解， $\nabla^2 f \geq 0 \Rightarrow \nabla f$  为增函数，即证！

2、根据公式 2.2，我们有

$$\begin{cases} f(y) \geq f(x) + \nabla f(x)^T (y - x) \\ f(x) \geq f(y) + \nabla f(y)^T (x - y) \end{cases}$$

将两式相加，即得

$$(\nabla f(x) - \nabla f(y))^T (x - y) \geq 0$$




证毕！

注：如果一个函数是严格凸的，并不能推出  $\nabla^2 f > 0$ ，一个反例就是  $f(x) = x^4$

#### 命题 2.1

给定函数  $f(x)$ ，如果  $g(t) = f(x + tv)$  是一个关于  $t$  的凸函数，则  $f(x)$  是凸函数。反之亦然。



(a) 对应  $\nabla f$  在  $x$  轴上方(b) 对应  $\nabla f$  穿过  $x$  轴(c) 对应  $\nabla f$  在  $x$  轴下方图 2.3:  $f$  图像的三种情况

**证明** 这里我们仅必要性，充分性同理可以推出。根据凸函数的性质，我们可以得到

$$g(\theta t_1 + (1 - \theta)t_2) \leq \theta g(t_1) + (1 - \theta)g(t_2) \quad (2.4)$$

再由  $g(t) = f(\mathbf{x} + t\mathbf{v})$ ，带入式2.4，得

$$\begin{aligned} f(\mathbf{x} + (\theta t_1 + (1 - \theta)t_2)\mathbf{v}) &= f(\theta(\mathbf{x} + t_1\mathbf{v}) + (1 - \theta)(\mathbf{x} + t_2\mathbf{v})) \\ &\leq \theta f(\mathbf{x} + t_1\mathbf{v}) + (1 - \theta)f(\mathbf{x} + t_2\mathbf{v}) \end{aligned}$$

证毕！

### 引理 2.1

对于函数  $g_1(\mathbf{x}), \dots, g_2(\mathbf{x})$  都是凸的，那么它们的非负凸组合得到的函数也是凸的。对于凹函数也有类似的结论。

### 引理 2.2

设  $f(\mathbf{x}, \mathbf{y})$  是一个凸函数，那么函数  $g(\mathbf{x}) = \sup_{\mathbf{y}} f(\mathbf{x}, \mathbf{y})$  也是一个凸函数。

## 复合函数的凸性与应用

所谓的复合函数，就是形如  $f(x) = h(g(x))$ ，我们假设它的性质足够好，具有二阶可导性。那么我们就可以得到

$$f''(x) = h''(g(x))g'(x)^2 + h'(g(x))g''(x) \quad (2.5)$$



**定理 2.1 (Rules for Composite Convex Functions)**

设  $f, g, h$  二阶可导, 且  $f(x) = h(g(x))$ , 那么

1. 如果  $h$  为凸函数, 并且不降,  $g$  为凸函数, 那么  $f$  为凸函数.
2. 如果  $h$  为凸函数, 不增,  $g$  为凹函数, 那么  $f$  为凸函数.
3. 如果  $h$  为凹函数, 不降,  $g$  为凹函数, 那么  $f$  为凹函数.
4. 如果  $h$  为凹函数, 不增,  $g$  为凸函数, 那么  $f$  为凹函数.



只需要将每个条件带入到  $f''(x)$  中, 观察它的正负即可验证。下面给出条件 1 的证明

$$h'' \geq 0, h' \geq 0, g'' \geq 0 \Rightarrow f'' \geq 0 \Rightarrow f \text{ 为凸函数}$$

幸运的是, 虽然定理 2.1 只是一维的情况, 但是其推广到多维。

## 强凸与强光滑性

**定义 2.5 (Strong Convexity)**

若函数  $f(\mathbf{x}) - \frac{m}{2}\|\mathbf{x}\|^2$  是一个凸函数, 那么  $f(\mathbf{x})$  就是一个凸性量为  $m$  的强凸函数。



定义 2.5 可以等价于公式 2.6, 下面给出证明

$$\begin{aligned} f(\theta \mathbf{x}_1 + (1-\theta)\mathbf{x}_2) &\leq \theta f(\mathbf{x}_1) + (1-\theta)f(\mathbf{x}_2) \\ &\quad - \frac{m}{2}\theta(1-\theta)\|\mathbf{x}_1 - \mathbf{x}_2\|^2 \end{aligned} \quad (2.6)$$

**证明** 由于  $f(\mathbf{x}) - \frac{m}{2}\|\mathbf{x}\|^2$  是一个凸函数, 根据凸函数的性质, 我们有

$$\begin{aligned} f(\theta \mathbf{x}_1 + (1-\theta)\mathbf{x}_2) - \frac{m}{2}\|\theta \mathbf{x}_1 + (1-\theta)\mathbf{x}_2\|^2 &\leq \theta(f(\mathbf{x}_1) - \frac{m}{2}\|\mathbf{x}_1\|^2) \\ &\quad + (1-\theta)(f(\mathbf{x}_2) - \frac{m}{2}\|\mathbf{x}_2\|^2) \end{aligned} \quad (2.7)$$

其实我们只需要证明??的等式形式就行了, 即证

$$\begin{aligned} &\frac{m}{2}\|\theta \mathbf{x}_1 + (1-\theta)\mathbf{x}_2\|^2 - \frac{m}{2}[\theta\|\mathbf{x}_1\|^2 + (1-\theta)\|\mathbf{x}_2\|^2] \\ &= -\frac{m}{2}\theta(1-\theta)\|\mathbf{x}_1 - \mathbf{x}_2\|^2 \end{aligned} \quad (2.8)$$

根据 2-范数的定义展开, 得

$$\begin{aligned} \|\theta \mathbf{x}_1 + (1-\theta)\mathbf{x}_2\|^2 &= \sum_{i=1}^n (\theta x_{1i} + (1-\theta)x_{2i})^2 \\ \|\mathbf{x}_1\|^2 &= \sum_{i=1}^n x_{1i}^2 \\ \|\mathbf{x}_2\|^2 &= \sum_{i=1}^n x_{2i}^2 \\ \|\mathbf{x}_1 - \mathbf{x}_2\|^2 &= \sum_{i=1}^n (x_{1i} - x_{2i})^2 \end{aligned}$$

将上面得式子带入公式 2.8 中, 证毕!

**注:** 没有额外加标识的范数都是 2-范数。

**定义 2.6 (Smoothness)**

如果  $\nabla f(\mathbf{x})$  满足  $\forall \mathbf{x}, \mathbf{y}, \|\nabla f(\mathbf{x}) - \nabla f(\mathbf{y})\| \leq L\|\mathbf{x} - \mathbf{y}\|, L > 0$ , 那么称它具有  $L$  的光滑性度量。



下面介绍一些相关的等价定理。

**定理 2.2**

以下几个性质是等价的：

- 1、  $f$  是强凸的，且凸性度量为  $m$ ；
- 2、  $(\nabla f(\mathbf{x}) - \nabla f(\mathbf{y}))^T(\mathbf{x} - \mathbf{y}) \geq m\|\mathbf{x} - \mathbf{y}\|^2, \forall \mathbf{x}, \mathbf{y}$ ；
- 3、  $\nabla^2 f(\mathbf{x}) \succeq mI, \forall \mathbf{x}$
- 4、  $f(\mathbf{y}) \geq f(\mathbf{x}) + \nabla f(\mathbf{x})^T(\mathbf{y} - \mathbf{x}) + \frac{m}{2}\|\mathbf{y} - \mathbf{x}\|^2$



定理之间的互推略过，可以参考本文的最后。

**定理 2.3**

以下几个性质是等价的：

- 1、  $\nabla f(\mathbf{x})$  是 Lipschitz 连续的，且光滑性度量为  $L$ ；
- 2、  $(\nabla f(\mathbf{x}) - \nabla f(\mathbf{y}))^T(\mathbf{x} - \mathbf{y}) \leq L\|\mathbf{x} - \mathbf{y}\|^2, \forall \mathbf{x}, \mathbf{y}$ ；
- 3、  $\nabla^2 f(\mathbf{x}) \preceq LI, \forall \mathbf{x}$
- 4、  $f(\mathbf{y}) \leq f(\mathbf{x}) + \nabla f(\mathbf{x})^T(\mathbf{y} - \mathbf{x}) + \frac{L}{2}\|\mathbf{y} - \mathbf{x}\|^2$



强凸和强光滑性是非常好的函数性质，而且就定理2.2和2.3就可以看出，它们利用了二阶信息，对函数分别提供了一个上界和一个下界。

本节主要参考了[凸优化 | 笔记整理 \(2\) —— 凸函数，强凸函数及相关拓展](#)

## 第3章 ODE

### 3.1 Lyapunov Stability Analysis

#### What is Lyapunov Stability?

早在 1892 年，俄国有一个叫李雅普诺夫的学者发表了一篇著名的文章《运动稳定性一般》问题，建立了关于运动稳定的一般理论，光看这个文章的名字就不一般，也确实，在尔后百余年，这个理论在数学、力学和控制理论中全面开花，已经成为稳定性研究方向的基础性理论，俄罗斯人对于数学上和工程上的直觉确实令人赞叹。



图 3.1

李雅普诺夫稳定性理论研究的是在扰动下平衡点的稳定性问题，可以将问题分为以下四种情况（如图3.2所示）：

1. 如果平衡状态  $x_e$  受到扰动后，仍然停留在  $x_e$  附近，我们就称  $x_e$  在李雅普诺夫意义下是稳定的（Lyapunov stable）；
2. 如果平衡状态  $x_e$  受到扰动后，最终都会收敛到  $x_e$ ，我们就称  $x_e$  在李雅普诺夫意义下是渐进稳定的（Asymptotically stable）；
3. 如果平衡状态  $x_e$  受到任何扰动后，最终都会收敛到  $x_e$ ，我们就称  $x_e$  在李雅普诺夫意义下是大范围内渐进稳定的（Asymptotically stable in large）；
4. 如果平衡状态  $x_e$  受到某种扰动后，状态开始偏离  $x_e$ ，我们就称  $x_e$  在李雅普诺夫意义下是不稳定的（Unstable）。




图 3.2: Lyapunov Stability

## 李雅普诺夫第二法

第二法比较天才，来源于一个朴素的想法：稳定的系统能量总是不断被耗散的，李雅普诺夫通过定义一个标量函数  $V(\mathbf{x})$ （通常能代表广义能量）来分析稳定性。这种方法的避免了直接求解方程，也没有进行近似线性化，所以也一般称之为直接法。

### 定理 3.1

如果标量函数  $V(\mathbf{x})$  满足：

- $V(\mathbf{x}) = 0$  if and only if  $\mathbf{x} = 0$
- $V(\mathbf{x}) > 0$  if and only if  $\mathbf{x} \neq 0$
- $\dot{V}(\mathbf{x}) = \frac{d}{dt}V(\mathbf{x}) = \sum_{i=1}^n \frac{\partial V}{\partial x_i} f_i(\mathbf{x}) \leq 0$  when  $\mathbf{x} \neq 0$

则称系统在李雅普诺夫意义下是稳定的，特别的，若  $\mathbf{x} \neq 0$  时，有  $\dot{V}(\mathbf{x}) < 0$ ，则系统是渐进稳定的。

本节主要参考了[如何理解李雅普诺夫稳定性分析](#)

## 3.2 Exponentially Stable

### 定义 3.1 (Exponentially Stable)

假设稳定点  $\mathbf{x}^* = 0$  为 Exponentially Stable 平衡点，那么满足存在两个正数  $k$  和  $\lambda$ ， $D = \{\mathbf{x} \in R^n \mid \|\mathbf{x}\| < r\}$ ， $\forall t \geq t_0, \forall \mathbf{x}(t_0) \in D$ ，使得

$$\|\mathbf{x}(t)\| \leq k\|\mathbf{x}(t_0)\|e^{-\lambda(t-t_0)} \quad (3.1)$$

其中  $\lambda$  为指数收敛率， $k$  为超调量。

### 定理 3.2

假设  $\mathbf{x} = 0$  为非线性系统  $\dot{\mathbf{x}} = f(\mathbf{x})$  的平衡点，且  $f(\mathbf{x})$  在  $\mathbf{x} = 0$  的邻域是连续可微的。令

$$A = \left. \frac{\partial f}{\partial \mathbf{x}} \right|_{\mathbf{x}=0} \quad (3.2)$$

当且仅当  $A$  是 Hurwitz Matrix(见定义1.4) 时， $\mathbf{x} = 0$  为非线性系统的 Exponentially Stable 平衡点。

### 定理 3.3 (Exponential stability theorem)

假设  $\mathbf{x} = 0$  为非线性系统  $\dot{\mathbf{x}} = f(\mathbf{x}, t)$  的 Exponentially Stable 平衡点， $\forall t \geq t_0, \forall \mathbf{x}(t_0) \in D$ ，存在函数  $V$  满足以下不等式：

$$\begin{aligned} c_1\|\mathbf{x}\|^2 &\leq V(t, \mathbf{x}) \leq c_2\|\mathbf{x}\|^2 \\ \frac{\partial V}{\partial t} + \frac{\partial V}{\partial \mathbf{x}} f(t, \mathbf{x}) &\leq -c_3\|\mathbf{x}\|^2 \\ \left\| \frac{\partial V}{\partial \mathbf{x}} \right\| &\leq c_4\|\mathbf{x}\| \end{aligned} \quad (3.3)$$

其中  $c_1, c_2, c_3, c_4$ ，为正常数。

### 3.3 Gronwall-Bellman Inequality

#### 定理 3.4 (Gronwall-Bellman Inequality)

设  $I = [a, b]$ ,  $\alpha, \beta, u$  为  $I$  上的实值函数,  $\alpha, u$  是  $I$  上的连续函数,  $\beta$  是非负的。如果  $u$  满足

$$u(t) \leq \alpha(t) + \int_a^t \beta(s)u(s)ds, \quad \forall t \in I \quad (3.4)$$

那么

$$u(t) \leq \alpha(t) + \int_a^t \alpha(s)\beta(s) \exp\left(\int_s^t \beta(r)dr\right) ds, \quad t \in I \quad (3.5)$$

如果  $\alpha$  是非递减函数, 我们可以得到

$$u(t) \leq \alpha(t) \exp\left(\int_a^t \beta(s)ds\right), \quad t \in I \quad (3.6)$$

**证明** 我们定义一个函数

$$v(s) = \exp\left(-\int_a^s \beta(r)dr\right) \int_a^s \beta(r)u(r)dr, \quad s \in I \quad (3.7)$$

求导, 得

$$v'(s) = \left( \underbrace{u(s) - \int_a^s \beta(r)u(r)}_{\leq \alpha(s)} \right) \beta(s) \exp\left(-\int_a^s \beta(r)dr\right), \quad s \in I \quad (3.8)$$

积分, 得

$$v(t) \leq \int_a^t \alpha(s)\beta(s) \exp\left(-\int_a^s \beta(r)dr\right) ds \quad (3.9)$$

再根据式3.7, 得

$$\begin{aligned} \int_a^t \beta(s)u(s)ds &= \exp\left(\int_a^t \beta(r)dr\right) v(t) \\ &\leq \int_a^t \alpha(s)\beta(s) \exp\left(\underbrace{\int_a^t \beta(r)dr - \int_a^s \beta(r)dr}_{=\int_s^t \beta(r)dr}\right) ds \end{aligned} \quad (3.10)$$

把式3.10代入式3.4, 即得式3.5。

再根据  $\alpha$  为非递减函数, 我们可以得到  $\alpha(s) \leq \alpha(t)$ , 带入式3.5, 即得

$$\begin{aligned} u(t) &\leq \alpha(t) + \left( -\alpha(t) \exp\left(\int_s^t \beta(r)dr\right) \right) \Big|_{s=a}^{s=t} \\ &= \alpha(t) \exp\left(\int_a^t \beta(r)dr\right), \quad t \in I. \end{aligned}$$

即证式3.6。

证毕!



## 第 4 章 Calculus

### 4.1 矩阵与范数求导

#### 4.1.1 梯度

##### 定理 4.1

假设  $\mathbf{x}$  为  $n$  维向量，在微分多元函数时经常使用以下规则：

- 1、对于所有  $\mathbf{A} \in \mathbb{R}^{m \times n}$ ，都有  $\nabla_{\mathbf{x}} \mathbf{A} \mathbf{x} = \mathbf{A}^T$
- 2、对于所有  $\mathbf{A} \in \mathbb{R}^{n \times m}$ ，都有  $\nabla_{\mathbf{x}} \mathbf{x}^T \mathbf{A} = \mathbf{A}$
- 3、对于所有  $\mathbf{A} \in \mathbb{R}^{n \times n}$ ，都有  $\nabla_{\mathbf{x}} \mathbf{x}^T \mathbf{A} \mathbf{x} = (\mathbf{A} + \mathbf{A}^T) \mathbf{x}$
- 4、 $\nabla_{\mathbf{x}} \|\mathbf{x}\|^2 = \nabla_{\mathbf{x}} \mathbf{x}^T \mathbf{x} = 2\mathbf{x}$



同样，对于任何矩阵  $\mathbf{X}$ ，都有  $\nabla_{\mathbf{x}} \|\mathbf{X}\|_F^2 = 2\mathbf{X}$ 。正如我们之后将看到的，梯度对于设计深度学习中的优化算法有很大用处。

#### 4.1.2 矩阵微分

##### 推论 4.1

假设  $\mathbf{x}$  是  $t$  的函数，则

$$\frac{d(\mathbf{x}^T \mathbf{A} \mathbf{x})}{dt} = (d\mathbf{x})^T \mathbf{A} \mathbf{x} + \mathbf{x}^T \mathbf{A} (d\mathbf{x}) \quad (4.1)$$



### 4.2 向量函数的 Taylor 公式

对于向量  $\mathbf{x}, \mathbf{x}_0$  和标量函数  $f(\mathbf{x})$ ，我们有

$$f(\mathbf{x}) = f(\mathbf{x}_0) + (\mathbf{x} - \mathbf{x}_0)^T \nabla f(\mathbf{x}_0) + \cdots \quad (4.2)$$

## 第 5 章 Game Theorem

## 第 6 章 Advanced Algebra

### 6.1 Gerschgorin Circle Theorem—特征值估计

#### 定理 6.1 (圆盘第一定理)

设  $A$  是  $n$  阶复矩阵,  $A = (a_{ij})_{n \times n}$ , 则  $A$  的特征值在复平面上的下列圆盘 (又称戈氏圆盘) 中:

$$|z - a_{ii}| \leq R_i, i = 1, 2, \dots, n$$

其中  $R_i$  为  $A$  的第  $i$  行元素去掉  $a_{ii}$  后的绝对值之和, 即

$$R_i = \sum_{j \neq i}^n |a_{ij}| = |a_{i1}| + \dots + |a_{i,i-1}| + |a_{i,i+1}| + \dots + |a_{in}|$$



#### 引理 6.1

设

$$f(x) = a_n x^n + a_{n-1} x^{n-1} + \dots + a_1 x + a_0$$

是  $n$  次复系数多项式, 则  $f(x)$  的  $n$  个根  $\lambda_1, \lambda_2, \dots, \lambda_n$  都是  $a_n, a_{n-1}, \dots, a_1, a_0$  的连续函数。



#### 定理 6.2 (圆盘第二定理)

设矩阵  $A = (a_{ij})_{n \times n}$  的  $n$  戈氏圆盘分成若干个连通区域, 若其中一个连通区域含有  $k$  个戈氏圆盘, 则有且只有  $k$  个特征值落在这个连通区域内 (若两个戈氏圆盘重合, 需计重数; 又若特征值为重根, 也计重数)。



本节主要参考了特征值的估计——圆盘定理 (Gerschgorin (戈氏) 圆盘第一定理) 和特征值的估计——圆盘定理 (Gerschgorin (戈氏) 圆盘第二定理), 在文章中会有具体的证明。

### 6.2 Jordan Form

#### 定义 6.1 (Jordan Form)

矩阵  $J$  除了主对角线和主对角线上方元素之外, 其余都是 0, 且主对角线上方的对角线的系数若不为 0 只能为 1。且这 1 的左方和下方的系数 (都在主对角线上) 有相同的值。

$$J = \text{Diag}(J_1, J_2, \dots, J_r) = \begin{pmatrix} \boxed{J_1} & 0 & \dots & 0 \\ 0 & \boxed{J_2} & \ddots & \vdots \\ \vdots & \ddots & \ddots & 0 \\ 0 & \dots & 0 & \boxed{J_r} \end{pmatrix} \quad (6.1)$$

其中  $J_1, J_2, \dots, J_r$  为 Jordan Block。易知对角矩阵是一种特殊的 Jordan 标准型矩阵。



**定义 6.2 (Jordan Block)**

形如矩阵  $J(\lambda, t)$  的形式被称为 Jordan Block。

$$J(\lambda, t) = \begin{pmatrix} \lambda & 0 & \cdots & 0 & 0 & 0 \\ 1 & \lambda & \cdots & 0 & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ 0 & 0 & \cdots & 1 & \lambda & 0 \\ 0 & 0 & \cdots & 0 & 1 & \lambda \end{pmatrix}_{(t \times t)} \quad (6.2)$$



**例题 6.1** 对于矩阵  $J$ ，它的 Jordan Block 为  $\begin{bmatrix} 1 \end{bmatrix}$ ， $\begin{bmatrix} 2 \end{bmatrix}$ ， $\begin{bmatrix} 4 & 1 \\ 0 & 4 \end{bmatrix}$ 。

$$J = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 2 & 0 & 0 \\ 0 & 0 & 4 & 1 \\ 0 & 0 & 0 & 4 \end{bmatrix}$$

## 6.3 矩阵特征值不等式

**定理 6.3**

对于任意向量  $\mathbf{x}$  和实对称矩阵  $A$ ，我们有

$$\lambda_{\min}(A) \leq \frac{\mathbf{x}^T A \mathbf{x}}{\mathbf{x}^T \mathbf{x}} \leq \lambda_{\max}(A) \quad (6.3)$$



**证明** 存在正交矩阵  $T$ ，满足

$$T^T A T = \begin{pmatrix} \lambda_1 & & & \\ & \lambda_2 & & \\ & & \ddots & \\ & & & \lambda_n \end{pmatrix}$$

令  $\mathbf{x} = T\mathbf{y}$ ，我们可以得到

$$\frac{\mathbf{x}^T A \mathbf{x}}{\mathbf{x}^T \mathbf{x}} = \frac{\mathbf{y}^T \begin{pmatrix} \lambda_1 & & & \\ & \lambda_2 & & \\ & & \ddots & \\ & & & \lambda_n \end{pmatrix} \mathbf{y}}{\mathbf{y}^T \mathbf{y}} = \frac{\lambda_1 y_1^2 + \lambda_2 y_2^2 + \cdots + \lambda_n y_n^2}{y_1^2 + y_2^2 + \cdots + y_n^2}$$

放缩，即得

$$\lambda_{\min}(A) \frac{y_1^2 + y_2^2 + \cdots + y_n^2}{y_1^2 + y_2^2 + \cdots + y_n^2} \leq \frac{\mathbf{x}^T A \mathbf{x}}{\mathbf{x}^T \mathbf{x}} \leq \lambda_{\max}(A) \frac{y_1^2 + y_2^2 + \cdots + y_n^2}{y_1^2 + y_2^2 + \cdots + y_n^2}$$

证毕！

# 附录 A [1]Distributed Nash Equilibrium Seeking by a Consensus Based Approach

## A.1 Terminology

1. penetration:n. 渗透
2. exploit:vt. 利用
3. utilize:vt. 利用
4. asynchronous:adj. 异步的
5. payoff:n. 收益
6. saddle point:n. 鞍点
7. permutation:n. 排列
8. consensus:n. 一致
9. protocol:n. 协议
10. collaboratively:adv. 合作的
11. convergence:n. 收敛
12. adoption:n. 采用
13. successively:n. 相继的
14. auxiliary:adj. 辅助的

## A.2 式 (8) 中的 Hurwitz Matrix

试证明  $-(L \otimes I_{N \times N} + B_0)$  是 Hurwitz Matrix

**证明** 对角线上的元素为  $-a_i - \sum_{j=1}^N a_{ij}, R_i = \sum_{j=1}^N |a_{ij}|$ , 根据定理6.1, 我们可以得到

$$\lambda_i \leq -a_i - \sum_{j=1}^N a_{ij} + R_i = -a_i \leq 0$$

特征值都小于等于 0, 故其为 Hurwitz Matrix。

## A.3 线性化式 (19)

我们取  $\mathbf{x} - \mathbf{x}_0 \rightarrow 0$ , 根据公式4.2, 我们有

$$\begin{aligned} \frac{\partial f_i(\mathbf{x})}{\partial x_i} &= \frac{\partial f_i(\mathbf{x}^*)}{\partial x_i} + (\mathbf{x} - \mathbf{x}^*)^T \left( \frac{\partial^2 f_i(\mathbf{x}^*)}{\partial x_i \partial \mathbf{x}} \right) \\ &= (\mathbf{x} - \mathbf{x}^*)^T \left( \frac{\partial^2 f_i(\mathbf{x}^*)}{\partial x_i \partial \mathbf{x}} \right) \end{aligned}$$

证毕!

## A.4 式 (20) 中 $\bar{k}$ Bis Hurwitz

根据定理6.1, 我们知道

$$|\lambda_i - \frac{\partial^2 f_i}{\partial x_i^2}| \leq R_i$$



即

$$\frac{\partial^2 f_i}{\partial x_i^2} - R_i \leq \lambda_i \leq \frac{\partial^2 f_i}{\partial x_i^2} + R_i$$

而

$$|\frac{\partial^2 f_i}{\partial x_i^2}| > |R_i|, \frac{\partial^2 f_i}{\partial x_i^2} < 0$$

所以  $\lambda_i < 0$ ,  $i = 1, 2, \dots, N$ , 证毕!